

Qudit-ADAPT para multiway number partitioning ($k = 3$)

Informe técnico

28 de septiembre de 2026

Resumen

Qudit-ADAPT aplicado a repartir n números en tres subconjuntos de igual suma, con un qutrit por número. 1378 simulaciones en BitWit, $n = 5-9$, 20 instancias de solución única por tamaño, cada una bajo 5 órdenes de sus números.

- El pool $\ell = 2$ resuelve más instancias que $\ell = 1$ en todo n : gana en 40 instancias contra 10 (prueba de signo $p = 2.4 \times 10^{-5}$). La tasa de éxito cae con n para ambos pools.
- La conjetura de que el warm start es una desventaja no se sostiene. Con $\ell = 2$, warm resuelve más que ADAPT desde $\theta = 0$: gana en 38 instancias contra 9 ($p = 2.5 \times 10^{-5}$). Con $\ell = 1$ no hay diferencia significativa (19 contra 14).
- Contra QAOA ($n = 5, 6$), $\ell = 2$ llega a $p_{\text{éxito}} \approx 1$ con 14–18 parámetros; un QAOA bien optimizado con 20 parámetros queda en $p_{\text{éxito}}$ mediana 0.44 ($n = 5$) y 0.11 ($n = 6$).
- El resultado de una corrida individual depende del orden, arbitrario, en que se asignan los números a los qutrits (empates en el criterio de gradiente). Todas las tasas se promedian sobre órdenes.

1 Problema y codificación

Números $a_1, \dots, a_n$; la caja del número j es el autovalor $z_j \in \{0, 1, 2\}$ del operador dígito $\hat{d}_j = L_z^{(j)} + I$. Con $\Sigma_i(z) = \sum_j a_j \delta_{i,z_j}$ y $\mu = \frac{1}{3} \sum_j a_j$ (formulación de J. Molina),

$$H_C = \sum_{i=0}^2 (\hat{\Sigma}_i - \mu)^2, \quad (1)$$

que vale 0 en una partición perfecta. H_C es Max 3-Cut sobre el grafo completo K_n con pesos $a_i a_j$, más una constante: $H_C = 2H_{3\text{-cut}}^{(a_i a_j)} + \frac{2}{3}(\sum_j a_j)^2$. Por lo tanto:

- El pool es el de K_n del paper: $2n^2 - n$ operadores con $\ell = 1$ y $\sim n^{3.65}$ con $\ell = 2$ (66 y 2724 en $n = 6$; 153 y 12 204 en $n = 9$). Cada operador actúa en ≤ 4 qutrits.
- El estado de referencia es $|+_3\rangle^{\otimes n}$, como en el paper.
- El error relativo y el approximation ratio del paper no aplican, porque $E_0 = 0$. La métrica es $p_{\text{éxito}}$, el peso del estado final sobre las soluciones óptimas.

2 Implementación

- H_C diagonal, guardado como vector de 3^n entradas. Sin matrices densas.
- $e^{-i\theta V_j}$ exacta, por diagonalización del bloque local ($\leq 81 \times 81$) y contracción contra el estado. Vale también para operadores simetrizados que no factorizan.
- Gradiente analítico por el método adjunto, entregado a BFGS (gto1= 10^{-10}).
- Validación: reconstruimos los 40 ansätze de J. Molina y reproducimos sus energías con diferencia máxima 7.7×10^{-12} . Sobre sus 40 instancias, nuestro ADAPT da el mismo $p_{\text{éxito}}$ (± 0.05) en 35/40.

3 Protocolo

- **Instancias.** Enteros distintos en $[1, 3n]$, con partición perfecta *única* (degeneración 6, la mínima por simetría de etiquetas). Son 20 por n para $n = 5-9$, deterministas por semilla (tabla 1).
- **Órdenes.** Cada instancia se corre bajo 5 permutaciones de sus números: la ascendente y 4 aleatorias. La unidad estadística es la instancia; su *tasa* es la fracción de órdenes que resuelve. Los IC del 95 % se obtienen por bootstrap sobre instancias, y las comparaciones pareadas se hacen con prueba de signo por instancia.
- **ADAPT.** $\epsilon = 10^{-3}$ en la norma del gradiente (escala de la ec. 1), tope de 150 parámetros.
- **Criterio de éxito.** Una corrida resuelve si $p_{\text{éxito}} \geq 0.1$: con 50 mediciones, la solución aparece con probabilidad $> 99\%$.
- **Inicialización.** Tres estrategias:
 - *warm*: $\theta_k = (\theta_{k-1}^*, 0)$, el ADAPT estándar.
 - (ii) *ADAPT desde $\theta = 0$* : se reoptimizan todos los parámetros desde cero en cada paso, es decir, desde $|+3\rangle^{\otimes n}$. Cambia qué operadores se eligen.
 - (i) *secuencia fija desde $\theta = 0$* : se reoptimiza desde cero, para cada k , la secuencia de operadores que eligió warm. Es el “cold start” de las Figs. 5–6 del paper.

Tabla 1: Una instancia por tamaño y su partición óptima. $p_{\text{éxito}}^{\text{azar}} = 6/3^n$ es el acierto al medir $|+3\rangle^{\otimes n}$.

n	rango	$p_{\text{éxito}}^{\text{azar}}$	números	cajas óptimas
5	[1, 15]	2.5×10^{-2}	[2, 3, 7, 8, 10]	10 3, 7 2, 8
6	[1, 18]	8.2×10^{-3}	[1, 6, 8, 10, 12, 17]	8, 10 6, 12 1, 17
7	[1, 21]	2.7×10^{-3}	[1, 4, 6, 10, 13, 16, 19]	10, 13 4, 19 1, 6, 16
8	[1, 24]	9.1×10^{-4}	[8, 9, 10, 11, 12, 14, 16, 19]	14, 19 10, 11, 12 8, 9, 16
9	[1, 27]	3.0×10^{-4}	[1, 2, 5, 6, 7, 8, 20, 21, 26]	6, 26 5, 7, 20 1, 2, 8, 21
10	[1, 30]	1.0×10^{-4}	[2, 3, 12, 15, 16, 17, 18, 22, 27, 30]	12, 15, 27 3, 16, 17, 18 2, 22, 30

4 Resultados

4.1 $\ell = 1$ contra $\ell = 2$

Tabla 2: Warm start, 20 instancias $\times$ 5 órdenes por fila. “Siempre / depende / nunca” cuenta instancias resueltas en los 5 órdenes, en algunos o en ninguno. “Conv.” son las corridas que terminaron por el criterio de gradiente y no por el tope. Nativas, MS y tiempo son medianas; las compuertas se cuentan con el Algoritmo 1 de Ringbauer *et al.*

n	ℓ	tasa	IC 95 %	siempre / depende / nunca	conv.	k	nativas	MS	tiempo
5	1	0.83	[0.68, 0.95]	13 / 5 / 2	100/100	10	129	18	0.2 s
	2	0.94	[0.89, 0.98]	15 / 5 / 0	100/100	13	216	34	1.0 s
6	1	0.67	[0.51, 0.82]	9 / 8 / 3	100/100	20	261	36	0.7 s
	2	0.85	[0.70, 0.97]	15 / 3 / 2	98/100	24	429	78	4.9 s
7	1	0.49	[0.31, 0.67]	6 / 8 / 6	100/100	18	227	32	1.1 s
	2	0.59	[0.41, 0.76]	8 / 8 / 4	91/100	42	776	134	21.2 s
8	1	0.25	[0.09, 0.43]	3 / 4 / 13	92/100	25	325	46	4.1 s
	2	0.57	[0.38, 0.75]	8 / 6 / 6	59/100	113	2137	384	6.3 min
9	1	0.13	[0.02, 0.28]	2 / 3 / 15	87/100	39	508	71	51.2 s
	2	0.22	[0.10, 0.36]	1 / 8 / 11	64/100	84	1608	289	8.6 min




Figura 1: (a) Tasa de éxito contra n , con IC del 95 %. (b) Tasa por instancia con $\ell = 1$ contra $\ell = 2$: sobre la diagonal gana $\ell = 2$ (con un pequeño desplazamiento aleatorio para separar puntos superpuestos).




Figura 2: Fracción de corridas con $p_{\text{éxito}} \geq 0.1$ en función de la iteración ADAPT (100 corridas por curva; una corrida que ya terminó conserva su valor final).

- $\ell = 2$ supera a $\ell = 1$ en todo n (tabla 2, fig. 1). Por instancia, $\ell = 2$ gana en 40 y $\ell = 1$ en 10 ($p = 2.4 \times 10^{-5}$). La mayor diferencia se da en $n = 8$.
- La tasa cae con n para ambos pools. En $n = 9$ ninguno pasa de un cuarto.
- Con $\ell = 1$ la fracción resuelta se estanca hacia $k \approx 30$; con $\ell = 2$ sigue subiendo hasta $k \approx 50$ ($n \leq 7$), $k \approx 80$ ($n = 8$) y $k \approx 110$ ($n = 9$) (fig. 2). Es lo mismo que la Fig. 4b del paper muestra para Max 3-Cut.
- Con $\ell = 2$, en $n = 8$ y 9 sólo 59 y 64 de 100 corridas convergen antes del tope de 150. Como la curva ya se aplanó, subir el tope debería dar ganancias modestas.
- $\ell = 2$ cuesta entre 1.6 y 6.6 veces más compuertas nativas que $\ell = 1$.

4.2 Warm start contra $\theta = 0$

- (ii) **ADAPT desde $\theta = 0$, con $\ell = 2$:** warm resuelve más en todo n ; la diferencia es grande en $n = 6, 8$ y 9 y mínima en $n = 7$ (tabla 3). Por instancia gana warm en 38 y (ii) en 9 ($p = 2.5 \times 10^{-5}$).
- **Con $\ell = 1$** no hay diferencia significativa: 19 contra 14 ($p = 4.9 \times 10^{-1}$). El signo cambia con n ; (ii) gana en $n = 6$, que es lo que se había visto con 10 instancias y un solo orden.

Tabla 3: Tasa de éxito de cada estrategia y comparación por instancia contra warm, en la forma “gana warm / gana la otra / igual”. La fila “todos” suma sobre n e incluye la prueba de signo.

ℓ	n	tasa			por instancia, contra warm	
		warm	(ii)	(i)	(ii) ADAPT desde 0	(i) secuencia fija
1	5	0.83	0.80	–	4 / 2 / 14	–
	6	0.67	0.78	–	1 / 7 / 12	–
	7	0.49	0.46	–	6 / 3 / 11	–
	8	0.25	0.20	–	4 / 1 / 15	–
	9	0.13	0.07	–	4 / 1 / 15	–
todos		19 / 14 ($p = 4.9 \times 10^{-1}$)				–
2	5	0.94	0.91	–	4 / 1 / 15	–
	6	0.85	0.69	–	8 / 1 / 11	–
	7	0.59	0.57	–	7 / 6 / 7	–
	8	0.57	0.35	–	11 / 0 / 9	–
	9	0.22	0.09	–	8 / 1 / 11	–
todos		38 / 9 ($p = 2.5 \times 10^{-5}$)				–




Figura 3: Tasa de éxito de las tres estrategias contra n , con IC del 95 %.

- **Mecanismo ($\ell = 2$).** La desventaja de (ii) no es de presupuesto: termina por el criterio de gradiente en 498/500 corridas, contra 412/500 de warm, y con circuitos más cortos (k mediano 44 contra 113 en $n = 8$). Encuentra la solución a mitad de camino casi tan seguido como warm (en $n = 8$, 0.59 contra 0.63 de las corridas superan $p_{\text{éxito}} = 0.1$), pero la pierde más a menudo: termina resuelta en 0.35 contra 0.57. Reoptimizar desde cero lleva a puntos donde todo el pool tiene gradiente pequeño, y ADAPT se detiene. Warm, en cambio, sigue descendiendo, como predice el argumento de *burrowing* del paper.
- **(i) secuencia fija desde $\theta = 0$:** en curso en BitWit.

4.3 Comparación con QAOA

J. Molina corrió QAOA para qutrits ($H_M = \sum_j L_x^{(j)}$, estado inicial $|+3\rangle^{\otimes n}$, CMA-ES con 25 reinicios, $p \leq 10$) sobre sus 20 instancias de $n = 5, 6$. Reconstruimos sus estados a partir de los parámetros guardados: las energías coinciden con las suyas a 1.6×10^{-12} .

- Su energía óptima *sube* al agregar capas en 116 de 180 pasos. Eso no puede ocurrir con un optimizador que converja, porque el circuito de p capas contiene al de $p - 1$. La causa es de escala: el γ útil es $\sim 10^{-2}$ (del orden de $1/\text{std}(H_C)$), y sortear en $[-\pi, \pi]$ cae casi siempre fuera de esa región.

- Lo reoptimizamos con el mismo circuito: barrido en grilla para $p = 1$, luego inicialización INTERP (Zhou *et al.*, PRX 2020) y BFGS. Así la energía baja monótonamente, entre 3 y 28 veces de $p = 1$ a $p = 10$.
- El QAOA de Max 3-Cut del paper (L-BFGS-B) no tiene este problema: su mejor energía baja monótonamente con p en los 8 grafos.

Tabla 4: Instancias de J. Molina (10 por n , genéricas y balanceadas): $p_{\text{éxito}}$ mediana y, entre paréntesis, instancias con $p_{\text{éxito}} \geq 0.1$. QAOA con $p = 10$ (20 parámetros); ADAPT con warm start, tope de 30 parámetros como en sus corridas, y k mediano.

n	QAOA (J. Molina)	QAOA reoptimizado	ADAPT $\ell = 1$	k	ADAPT $\ell = 2$	k
5	0.04 (2/10)	0.44 (10/10)	0.97 (8/10)	28	1.00 (10/10)	14
6	0.01 (0/10)	0.11 (5/10)	0.64 (10/10)	14	0.97 (10/10)	18

Con un número similar de parámetros, ADAPT $\ell = 2$ supera a un QAOA bien optimizado (tabla 4). La conclusión cualitativa del cuaderno de J. Molina se sostiene, pero con una brecha menor que la que muestran sus números.

4.4 Sensibilidad al orden, a la máquina y al rango

- **Orden.** Los empates en $\arg \max_j |g_j|$ se resuelven por índice, y el índice depende de qué número va en qué qutrit. En $n = 6$, con 10 órdenes por instancia y $\ell = 1$, 9 instancias se resuelven siempre, 3 nunca y 8 dependen del orden (fig. 4).
- El orden ascendente no es sistemáticamente peor: difiere de los otros órdenes en ≤ 0.08 en todos los casos salvo $n = 6$, $\ell = 1$ (0.50 contra 0.71).
- **Máquina.** Entre 1 y 2 hilos de BLAS en la misma máquina cambia el veredicto en 0/20 corridas; entre la laptop y BitWit, en 1/20. El orden ascendente reproduce el veredicto de las corridas anteriores en 120/120 casos.
- **Rango.** En $n = 6$, los números en $[1, 8]$ (las 9 instancias posibles) no son más fáciles que en $[1, 18]$: con $\ell = 1$ se resuelven 3/9 contra 10/20, y con $\ell = 2$, 8/9 contra 18/20.




Figura 4: $p_{\text{éxito}}$ de las 20 instancias de $n = 6$ ($\ell = 1$, warm) bajo 10 órdenes.

4.5 Otras observaciones

- **Respuestas perdidas.** Entre las corridas warm que fallan, 17/263 ($\ell = 1$) y 25/183 ($\ell = 2$) superaron $p_{\text{éxito}} = 0.1$ a mitad de camino y la perdieron mientras la energía seguía bajando (fig. 5). Minimizar

$\langle H_C \rangle$ no obliga a concentrarse en la solución.

- $p_{\text{éxito}} \approx 0.5$. 116 de 500 corridas con $\ell = 2$ terminan con el peso repartido por mitades entre la solución y una partición que intercambia dos números que difieren en 1. Parece un punto estacionario por simetría; queda por analizar.
- **Varianza del gradiente** ($n = 6-14$, $\ell = 1$, puntos aleatorios): decae como $e^{-\alpha n}$ con $\alpha = 0.38$, contra $\ln 3 \approx 1.10$ para un 2-diseño; en $n = 14$ es 241 veces la de un 2-diseño, y no depende de la profundidad (fig. 6).
- $n = 13$, $\ell = 1$: una corrida convergió en 64 parámetros (7.7 h). $p_{\text{éxito}}$ alcanzó 2.9×10^{-3} en $k = 12$ y terminó en 3.1×10^{-45} .




Figura 5: $p_{\text{éxito}}$ contra número de parámetros, $n = 6$, una instancia, $\ell = 1$. Warm llega a 0.11 y la pierde; ADAPT desde $\theta = 0$ termina en 0.97.




Figura 6: Varianza del gradiente en puntos aleatorios contra n , y referencia de un 2-diseño anclada en $n = 6$.

5 Conclusiones

- MWNP con $k = 3$ es Max 3-Cut ponderado sobre K_n , y entra en el paper con el mismo pool y el mismo estado de referencia. La métrica tiene que ser $p_{\text{éxito}}$, porque $E_0 = 0$.
- El pool $\ell = 2$ es significativamente mejor que $\ell = 1$, pero ambos pierden eficacia con n .
- El warm start no es una desventaja. Con $\ell = 2$ es claramente mejor que reiniciar desde $\theta = 0$, porque este último detiene ADAPT antes; con $\ell = 1$ son equivalentes.
- ADAPT $\ell = 2$ supera a QAOA bien optimizado con un número de parámetros similar.
- Las corridas individuales dependen del orden de los números. Cualquier tasa reportada tiene que promediarse sobre órdenes o sobre un desempate aleatorio.

6 Pendientes

- Subir el tope de $\ell = 2$ a 300 parámetros en $n = 8, 9$.
- Explicar el estancamiento en $p_{\text{éxito}} \approx 0.5$.
- QAOA reoptimizado sobre las instancias del benchmark ($n = 5-9$) y conteo de compuertas nativas a igual número de parámetros, como en la tabla IV del paper.